

AI시대의 컴퓨터 개론

인공지능과 빅데이터를 위한 필수 교양서



06

인공지능과 딥러닝

단원 목차

- 6.1 인공지능 개요
- 6.2 머신러닝
- 6.3 인공신경망과 딥러닝



단원 학습목표

- 제4차 산업혁명의 핵심 기술인 인공지능 정의와 활용을 알아본다.
- 인공지능에서의 머신러닝과 딥러닝의 차이를 알아본다.
- 머신러닝 문제에서 다루는 회귀와 분류를 알아본다.
- 인공신경망과 심층신경망의 정의와 내부 동작 방식을 알아본다.
- 텐서플로로 대표되는 다양한 인공신경망 라이브러리를 알아본다.

06

인공지능과 딥러닝

단원 목차

6.1 인공지능 개요

6.2 머신러닝

6.3 인공신경망과 딥러닝



미래학자인 레이 커즈와일은 강한 인공지능의 출현 시점을 2045년으로 예측 했다가 2030년으로 앞당겼다고 함

• 인공지능(AI: Artificial Intelligence)

- 사고나 학습, 문제해결 능력 등 인간 지능 수준의 지적 능력을 컴퓨터 하드웨어와 소프트웨어로 구현하는 기술




그림 6.1 ▶ 약한 인공지능과 강한 인공지능

인공지능은 본격적으로 '인간처럼 생각하는 컴퓨터'로 연구된 지 80여 년이 넘는 컴퓨터과학 연구의 한 분야

- **1943년, 워런 맥컬럭(Warren McCulloch)**

- 인간 두뇌 신경(뉴런)에서 착안한 논리적 모델을 제시
- 이 모델이 인공신경망 퍼셉트론의 원류

- **앨런 튜링(Alan Turing)**

- 1950년 자신의 논문인 'The Imitation Game'에서 '튜링 테스트'를 제안
- 튜링 테스트

- '기계도 생각할 수 있는가?'라는 테스트

- '지능적 기계의 개발 가능성과 학습하는 기계'에 관한 인공지능의 개념적 토대를 제공

- **1956년, 다트머스 회의**

- 존 매카시(John McCarthy), '인공지능'이라는 용어를 처음 사용
- 인공지능이 학문 분야로 발전되는 계기

Perceptron: 1957년 프랭크 로젠블랫(Frank Rosenblatt)

이 시대의 컴퓨터 개론
인공지능과 빅데이터를 위한 필수 교양서

퍼셉트론은 인간의 뇌 신경(뉴런)에서 아이디어를 얻어 여러 신호를 입력 받아 하나의 신호를 출력하는 모델

- **인공신경망의 근간이 되는 퍼셉트론(perceptron)을 개발**
- **뉴욕타임즈는 인공지능의 희망찬 미래를 말하기도**
 - 퍼셉트론 기반으로 스스로 학습하는 기기의 기사 발표
 - **조만간 걷고, 말하고, 보고, 쓰며 자아를 인식하는 컴퓨터가 출현 예상**




그림 6.2 ▶ 로젠블랫과 퍼셉트론

NEW NAVY DEVICE LEARNS BY DOING

Psychologist Shows Embryo
of Computer Designed to
Read and Grow Wiser

WASHINGTON, July 7 (UPI) —The Navy revealed the embryo of an electronic computer today that it expects will be able to walk, talk, see, write, reproduce itself and be conscious of its existence.

The embryo—the Weather Bureau's \$2,000,000 "704" computer—learned to differentiate between right and left after fifty attempts in the Navy's demonstration for newsmen.

The service said it would use this principle to build the first of its Perceptron thinking machines that will be able to read and write. It is expected to be finished in about a year at a cost of \$100,000.

Dr. Frank Rosenblatt, designer of the Perceptron, conducted the demonstration. He said the machine would be the first device to think as the human brain. As do human be-

ings, Perceptron will make mistakes at first, but will grow wiser as it gains experience, he said.

Dr. Rosenblatt, a research psychologist at the Cornell Aeronautical Laboratory, Buffalo, said Perceptrons might be fired to the planets as mechanical space explorers.

Without Human Controls

The Navy said the perceptron would be the first non-living mechanism "capable of receiving, recognizing and identifying its surroundings without any human training or control."

The "brain" is designed to remember images and information it has perceived itself. Ordinary computers remember only what is fed into them on punch cards or magnetic tape.

Later Perceptrons will be able to recognize people and call out their names and instantly translate speech in one language to speech or writing in another language, it was predicted.

Mr. Rosenblatt said in principle it would be possible to build brains that could reproduce themselves on an assembly line and which would be conscious of their existence.

1958 New York Times...

In today's demonstration, the "704" was fed two cards, one with squares marked on the left side and the other with squares on the right side.

Learns by Doing

In the first fifty trials, the machine made no distinction between them. It then started registering a "Q" for the left squares and "O" for the right squares.

Dr. Rosenblatt said he could explain why the machine learned only in highly technical terms. But he said the computer had undergone a "self-induced change in the wiring diagram."

The first Perceptron will have about 1,000 electronic "association cells" receiving electrical impulses from an eye-like scanning device with 400 photo-cells. The human brain has 10,000,000,000 responsive cells, including 100,000,000 connections with the eyes.

그림 6.3 ▶ 1958년 뉴욕 타임즈의 퍼셉트론 기사

겨울: 연구 자금 지원이 위축되는 침체기

• 1969년

- 기호주의의 마빈 민스키(Marvin Minsky)와 시모어 페퍼트(Seymour Papert)
 - 퍼셉트론이 XOR 같은 문제도 해결할 수 없다고 증명
 - 퍼셉트론을 여러 층 쌓은 다층 퍼셉트론(MLP: Multilayer Perceptron)이 문제를 해결할 수 있지만
 - 이를 학습시킬 방법이 없다고 지적

• 'XOR문제' 이후에 민스키의 기호주의 학문으로 관심이 집중되는 계기

- 기호주의도 한계에 도달
 - 이후 인공지능은 침체기
- 1970년대에 걸쳐 이어졌던 이 침체기를 인공지능의 첫 번째 겨울

- **인공신경망 분야는 2000년대 중반까지 또 한번의 겨울을 맞음**
 - 1990년대에 접어들면서 입력 데이터에서 특징의 수가 증가
 - 구조가 복잡해지면서 여러 문제가 발생
 - 인공신경망에서 뉴런 층이 많아질수록 예상과는 달리 여러 문제 학습에 문제 발생
 - 경사 소실(Vanishing Gradient), 과적합(overfitting), 극소(local minimum) 등
 - 이러한 용어가 있다는 정도만 이해
- **1995년 이후, 활성화된 머신러닝**
 - 컴퓨터가 대량의 데이터를 기반으로 스스로 학습하고 통계적인 결과를 도출
 - 인공지능의 한 분야로 다음과 같은 알고리즘
 - 서포트 벡터 머신(SVM: Support Vector Machine)
 - 결정트리(decision tree)
 - 랜덤 포레스트(random forest)
 - 인공신경망보다 간단하면서도 더 좋은 성능을 나타내기 시작

인공신경망 기술의 발전

- **1998년, 안 르쿤**

- 합성곱 신경망(CNN: Convolutional Neural Network) 기술 발표
- 이미지 처리 분야 등에 널리 활용

- **2006년, 힌튼**

- 본격적인 딥러닝(deep learning) 시대를 견인, 용어 처음 사용
 - 여러 기술적 해결책을 제시해 심층 신경망도 학습할 수 있음을 밝힘
- 심층신경망(DNN: Deep Neural Network) 사용
 - 신경망(neural network)에 deep을 붙여

- **2012년 구글 브레인과 스탠포드의 앤드류 응(Andrew Ng)**

- 유튜브의 1000만 마리 고양이 얼굴을 인식

- **2012년, CNN 기반의 알렉스넷(AlexNet)**

- 이미지 분류 경진대회인 ILSVRC(ImageNet Large Scale Visual Recognition Challenge) 대회
 - 이미지 인식 오차율이 15%로 다 른 팀에 비해 무려 10%가 낮은 기록으로 우승

1970년대의 첫 번째 겨울과 1990년대 두 번째 겨울을 거쳐 현재 인공지능이 가장 활성화된 시기를 지나고 있음

- 2016년 3월, 구글 딥마인드의 알파고(AlphaGo)

- 인공지능이란 용어를 우리들에게 각인

- 사람들은 인공지능의 발전에 두려움까지 느끼게 되는 계기

- 인공신경망 분야

- 발전을 거듭해 다양한 분야에서 인공지능 분야보다도 좋은 성능을 보여 줌




그림 6.9 ▶ 인공지능의 역사

인공지능의 이미지 분석은 의료영상 분석 및 인식 분야에 널리 활용

- **얼굴을 인식해 온도를 측정하는 기기**
 - 코로나로 인해 백화점이나 식당 입구에서 활용
- **흉부 엑스레이 사진을 분석, 주요 폐 질환을 97%의 정확도로 검출**
 - 인공지능 기술로 분석




이안 굿펠로(Ian Goodfellow)가 만든 생성적 적대 신경망(GAN: Generative Adversarial Network)이 활용되면서 인공지능은 모방과 창조가 가능

• 2017년, 버클리 대학 인공지능연구소, 순환 GAN(cycleGAN) 모델 개발

- GAN 구조에 원래 이미지의 형태를 잘 유지할 수 있는 조건을 추가

- 주어진 사진을 모네 화풍의 그림으로, 그 반대도 가능
- 얼룩말과 일반 말을 서로 바꾸고, 여름 산과 겨울 산과의 변환도 가능



딥페이크(deep fake)는 원본 이미지나 동영상 위에 다른 영상을 중첩하거나 결합하여 원본과는 다른 콘텐츠를 생성하는 기술

- 2017년 워싱턴대학교 컴퓨터공학부 연구 팀

- 오바마의 목소리에 맞춰 립싱크로 말하는 '오바마 AI'를 만들

- 오바마 대통령의 실제 연설에서 음성을 추출한 후

- 음성에 맞게 입 모양과 표정을 학습시켜 새로운 영상을 만들

- 산업적 활용가치가 높아 영화 음반 등 다양한 분야에서 활용 가능

- 가짜 뉴스 등의 심각한 문제



그림 6.18 ▶ 오바마 생성 영상과 합성 과정

유튜브나 넷플릭스를 어느 정도 사용하면 계속 내가 좋아할 만한 영상이 계속 추천

• 개인화된 맞춤형 추천서비스

- 개인의 취향과 관심에 맞는 것을 찾아 줌
- 자신의 선택 이력과 다른 사용자의 선택 이력 자료를 기반

• 학습을 통해 개인화된 맞춤형 추천서비스가 가능

• 스팸 메일 필터링, 이상 활동 점검

- 여러 컴퓨터에서 메일을 사용하면 자신이 맞는지 확인
- 카드나 은행의 부적 절한 거래도 인공지능에 의해 감지

실시간 이상 감지



그림 6.19 ▶ 이상 감지 과정

많은 미래학자들은 늦어도 21세기 내에는 인공지능이 인간의 두뇌를 따라잡을 것으로 예상

• 언제 인간의 뇌를 능가하는 인공지능이 나올까?

- 미래학자 레이 커즈와일(Ray Kurzweil)

• 과거 스마트폰과 자율주행차를 예언

- 2029년에 가능할 것으로 예측

• 인공지능

- 인류와 함께 살아가는 도구로 우리의 지적·신체적 한계를 넓혀주는 역할

- 인류의 어려운 문제 해결

• 번역기: 전 인류가 편히 소통

• '특이점(Singularity)'

- 인공지능이 인간 뇌의 능력을 넘어서는 순간

- 특이점이란 말은 1950년대 처음 등장

- 컴퓨터과학자 폰 노이만

• 『기술적 특이점』으로 정의

- '기술의 가속된 발전으로 인해 인류의 삶을 완전히 바꿀 변곡점'



그림 6.21 ▶ 특이점(Singularity)

06

인공지능과 딥러닝

단원 목차

6.1 인공지능 개요

6.2 머신러닝

6.3 인공신경망과 딥러닝



인공지능이라는 용어가 나올 때마다 항상 함께 나오는 머신러닝과 딥러닝은 무엇이고 어떻게 다를까?

- 인공지능이 가장 큰 범주

- 인간의 지능을 구현

- 머신러닝

- 데이터를 기반으로 기계 스스로 학습하는 인공지능의 한 분야

- 심층신경망인 딥러닝(deep learning)

- 머신러닝의 여러 분야 중에서
 - 2010년 이후 현재의 인공지능 붐을 주도하고 있는 기술
 - 퍼셉트론으로 구성된 인공신경망
 - 여러 단계의 심층 학습을 통하여 스스로 학습하는 기술




그림 6.23 ▶ 인공지능과 머신러닝, 딥러닝의 이해

1959년 아서 사무엘(Arthur Samuel)이 머신러닝(machine learning)이라는 용어를 처음 사용해 대중화시킴

• 사무엘의 머신러닝 정의

- "머신러닝은 컴퓨터가 인간처럼 학습하고 행동하도록 하는 과학이며,
- 관찰 및 실제 단어의 상호작용 형태로 데이터와 정보를 제공함으로써
- 시간이 지남에 따라 자율적 으로 학습을 향상시키는 과학이다."

• 일반적 기계학습 정의

- 주어진 데이터를 기반으로 기계가 스스로 학습
 - 성능을 향상시키거나 최적의 해답을 찾기 위한 지능적 학습 방법
- 컴퓨터가 스스로 학습을 할 수 있도록 해주는 인공지능의 한 형태
 - 명시적(explicit)으로 프로그래밍이 필요 없음
- 데이터는 매우 중요
 - 더 많은 데이터가 유입되면 컴퓨터는 더 많이 학습
 - 시간이 흐르면서 스마트해져서 작업을 수행하는 능력과 정확도가 향상

사람에겐 너무 쉬운 일이나, 컴퓨터에게 개와 고양이 이의 분류를 맡긴다면 어떨까?

• 전통적 프로그래밍 방식으로 해결

- 개와 고양이 생김새의 특징을 세부적 코딩
- 외모 특징 자체를 찾는 것도 어려운 문제
 - 이러한 전통적 방식의 코딩 결과는 좋지 않음
 - 명시적으로 프로그래밍(explicit programming)
 - 입력 데이터를 사용하고 프로그램을 실행하여 출력을 생성

• 머신러닝 방법

- 우리 인간이 어린 시절 부모 도움의 학습으로 개와 고양이를 자연스럽게 분류하는 방법
 - 개와 고양이 사진에서 반복되는 패턴을 인지해 스스로 학습하는 방식
- 스스로 데이터를 반복적으로 학습하여 기술을 터득하는 방식
 - 입력 데이터와 정답이 있는 출력이 알고리즘에 공급되어 프로그램(모델)을 생성
 - 알고리즘이 데이터에서 학습을 해 자동으로 규칙을 공식화
 - 즉 머신러닝 모델을 통해 미래의 결과를 예측



그림 6.26 ▶ 전통적 프로그래밍과 머신러닝의 차이

• 데이터 수집

- 수집된 데이터의 품질과 양에 따라
 - 예측 모델의 성능이 결정
- 머신러닝 과정에서 가장 중요한 단계

• 데이터 전처리

- 잘못된 값은 수정하는 데이터 정리 필요
 - 누락 값을 채우고
 - 이상 값을 수정하거나 제거
- 정규화(normalization) 과정도 필요
 - 데이터 특성마다 차이가 너무 크면
 - 머신러닝 모델에 따라 값을 비슷한 크기로 조정
- 데이터 변환 작업이 필요
 - 모델의 계산에 적합한 자료구조로
 - 기초 자료로 새로운 자료를 생성

• 모델 학습

- 적절한 머신러닝 모델을 생성해 데이터로 학습

• 성능 개선

- 학습된 모델의 성능을 시험하고 보다 좋은 결과를 도출

• 시각화

- 데이터와 머신러닝 과정 그리고 예측 결과를 보기 좋게 시각화하는 과정

머신러닝은 데이터에 숨겨진 정보를 찾는 분야로 데이터가 무엇보다 중요

• 데이터 집합(data set)

- 머신러닝의 데이터

• 중고 자동차 데이터 예

- 엑셀의 테이블 형태 자료

• 9개의 열

• 제조사와 모델, 색상, 사용
기간, 배기량, 주행거리,
연료, 신차가격, 중고가격

- 표본(sample)

• 인스턴스(instance)

• 데이터 포인터(data
pointer)

- 실제 중고 자동차 개
개의 자료인 행

- 표본 수(# of samples)

• 데이터 수인 행 수

특징 $X_1, X_2, X_3, \dots$									정답(label) Y
	제조사	모델	색상	사용기간	배기량	주행거리	연료	신차가격	중고가격
1	현대	제네시스	흰색	5.6	3,200	78,000	가솔린	50,000,000	12,000,000
2	기아	카니발	검정색	3.0	2,100	30,000	디젤	45,000,000	1,300,000
3	르노삼성	SM6	회색	2.2	1,300	2,000	가솔린	37,000,000	1,000,000
4	쌍용	티볼리	흰색	7.3	1,450	63,000	가솔린	41,000,000	5,300,000
...									
100	쉐보레	말리부	빨간색	4.5	1,320	44,000	가솔린	39,000,000	2,700,000

표본 수 100

그림 6.28 ▶ 머신러닝에서 사용되는 전형적인 테이블 형태의 데이터

특이값이나 결측값은 머신러닝 성능에 영향을 미치므로 사전 처리가 필요

- **특이값(outlier) 또는 이상치**

- 정상적인 범주를 벗어난 값

- **결측값(missing value) 또는 결측치**

- 빠진 데이터 값

- **중고가격 예측 예**

- 특성(features) 또는 특성 벡터(features vector)

- 예측값을 위한 속성인 제조사와 색상 등 8개

- 예측값 또는 목표(target) 값

- 마지막 열(정답)인 중고가격

- 레이블(label)

- 이미 아는 정답

- 정답이 확보된 데이터를 레이블 데이터(labeled data)

- **특징과 목표값, 수학 집합으로 표시**

- 중고 자동차 데이터에서는 목표 값이 중고가격인 y_1 하나인 경우

특징 표현이 차수가 높으면
여러 개로 표현

$$X = \{x_1, x_2, x_3, \dots, x_n\}, Y = \{y_1, y_2, y_3\}$$

그림 6.29 ▶ 데이터의 특성과 정답(레이블)

주어진 문제를 해결하기 위해 데이터로 알고리즘을 학습시키면 바로 머신러닝 모델이 생성

• 머신러닝 모델

- 내부의 알고리즘으로 특정 유형의 패턴을 인식
 - 문제를 해결
- 훈련(학습) 과정을 통해
 - 데이터에 가장 적합한 매개변수로 설정된 알고리즘 준비
- 처음엔 몰랐던 매개 변수 값을
 - 스스로 학습을 통해 값을 결정
 - 정답이 붙은 학습 데이터로 모델을 학습
- 머신러닝 모델의 예측
 - 새로운 테스트 데이터에 대한 결과를 예측




그림 6.30 ▶ 머신러닝 모델




그림 6.31 ▶ 머신러닝 모델과 데이터

현재 머신러닝 모델이 제대로 학습되고 있는지를 판단하려면 훈련에 사용되지 않은 검증 데이터로 모델의 정확도(accuracy)나 손실함수(loss function)를 평가해 지속적으로 모델의 성능을 개선

• 데이터 분리

- 학습(훈련) 데이터(training data)와 테스트(검사 또는 시험) 데이터(test data)로 나눔

• 학습 데이터

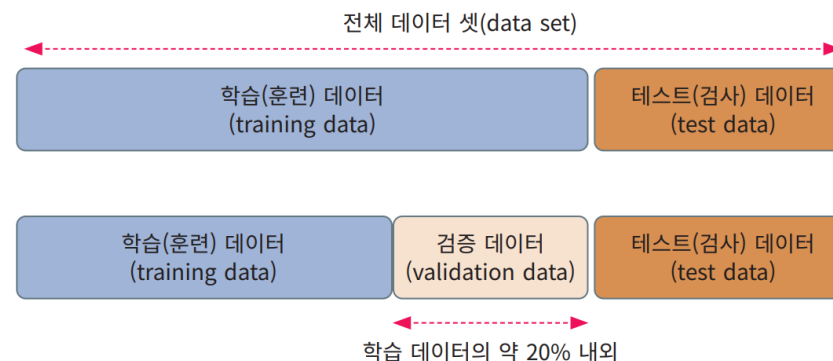
- 다시 학습 데이터(training data)와 검증 데이터(validation data)로 나눌 수 있음
- 학습에 사용되는 데이터
 - 참고서 연습문제 시험에 비유
- 검증 데이터
 - 학습 향상을 점검하기 위한 데이터, 모의고사에 비유

• 테스트 데이터

- 최종 모델 성능에 활용되는 데이터
 - 학습이 잘 되었는지 최종 검사에 사용, 수능 시험에 비유

• 지속적으로 모델의 성능을 개선에 필요한 기준 값(뒤에서 좀 더 자세히 설명됨)

- 손실함수(loss function)
 - 현재 모델의 예측의 오류 정도를 나타내는 값으로 작을수록 좋은 함수 값
- 정확도(accuracy)
 - 예측값과 정답의 일치하는 수준이라고 이해



머신러닝을 통해 해결하고자 하는 문제는 크게 회귀(regression)와 분류(classification)로 나뉨

• 회귀

- 연속값(continuous value)을 예측하는 문제

- 가격, 급여, 연령, 온도 등

• 분류



- 불연속적인 이산값(discrete value)을 예측

- 사과와 배, 남성과 여성,
- 참거나 더움, 참 또는 거짓
- 클래스(class)


- 구분해야 할 유형

- 유형 수(# of classes)

- 남성과 여성을 분류해야 한다면 2



회귀(regression)



분류(classification)

처음 주어진 정답이 없는 왼쪽의 파란 데이터에서 오른쪽과 같이 주어진 데이터들을 가장 잘 설명하도록 그룹을 찾아내는 것이 군집화의 목적

• 군집화(clustering)

- 정답이 없는 학습인 비지도 학습의 일종
 - 군집(cluster)으로 나누는 작업
 - 주어진 데이터들을 유사한 특성을 가진 그룹으로 분리
- 그룹인 클러스터의 수
 - 알고리즘에 따라 미리 결정된 수

• 군집화 활용

- 고객의 성향을 분석해
 - 비슷한 성향의 고객끼리 군집으로 나누는 고객 세분화




그림 6.34 ▶ 군집화 과정(i.stack.imgur.com/cIDB3.png)

머신러닝은 용어 의미대로 '컴퓨터가 스스로 학습하여 문제를 해결하는 방법'

• 지도 학습과 비지도 학습, 반지도 학습 그리고 강화 학습으로 나뉨


지도 학습(Supervised Learning)

문제와 정답을 모두 알려주고 공부시키는 방법



반지도 학습(Semi supervised Learning)

지도 학습과 비지도 학습을 섞어서 사용하는 학습 방식




비지도 학습(Unsupervised Learning)

답을 가르쳐주지 않고 공부시키는 방법





강화 학습(Reinforcement Learning)

보상을 얻기 위한 정책을 다음 행동에 반영시키는 방법



훈련 과정에서 입력값 X_{data} 가 주어지면 입력값에 대한 정답(label)인 Y_{data} 로 학습

- 정답이 있는 훈련 데이터(labeled data)로부터 입출력 간의 함수인 모델을 학습
- 분류와 회귀 문제
 - 분류(classification): 주어진 데이터를 정해진 정답 유형에 따라 분류하는 문제
 - 사과와 배, 오렌지를 분류하는 지도 학습
 - 회귀(regression): 입력 데이터로부터 연속된 출력값을 예측하는 문제
 - 키로부터 몸무게를 예측하거나 지역과 평형으로 아파트 값을 예측
- 신용카드 부정사용 감지: 회귀 or 분류 어느 것일까요?



정답 레이블이 없는 데이터를 비슷한 특징끼리 군집화해 새로운 데이터에 대한 결과를 예측하는 방법

- **데이터 내에 숨어있는 어떤 관계를 찾아 내는 방법**

- 정답이 없는 데이터로부터 패턴이나 형태를 찾아야 하기 때문에 지도 학습보다 더 어려움


- **준지도 학습: 반지도 학습(semi-supervised learning)**

- 지도 학습과 비지도 학습을 섞어서 사용하는 학습 방식

- **비지도 학습의 대표적인 종류는 군집화(clustering)**

- 사과와 배, 오렌지 등으로 군집화

- **과일의 사진에서 각각의 사진 데이터에 대해 색깔이 무엇인지, 모양이 어떠한 지 등에 대한 특징**



주어진 현재 상황(situation)에서 보상(reward)을 최대화 하도록 다음 행동(action)을 학습시키는 방법으로 개에게 좋아하는 먹이를 주며 개를 훈련시키는 방법에 비유

• 강화 학습(reinforcement learning)

- 어느 주어진 환경(environments)에서 학습 주체인 대리인(agent)에게 지시한 명령에 대해
 - 대리인을 관찰(observation)
- 다음 행동(action)을 하면
 - 잘못된 행동에 대해서는 벌
 - 잘한 행동에 대해 보상
 - 대리인은 가장 큰 보상을 얻기 위한 정책(policy)을 통해 스스로 학습하는 방법

• 강화 학습 비유

- 아기가 걸음을 걷는 학습 과정
- 어릴 적 자전거를 배우는 과정

• 강화 학습 사례

- 게임이나 자율주행 등에 주로 활용되는 기법
 - '궁극적인 목표는 있지만, 그에 이르는 과정은 정답이 없는 상황'
- 알파고(AlphaGo)

통계 분야에서 오랫동안 연구된 선형 모델은 현재 머신러닝 분야에서도 널리 쓰이고 있는 기법

• 선형 모델

- 데이터 특성에 대한 선형 함수를 만들어 예측하는 기법



만일 입력 데이터의 특성의 수(차수)가 n 이라면 선형 모델의 식은 다음과 같다. 선형 모델이 학습을 통해 구해야 할 값이 $w_1, w_2, \dots, w_n, b$ 등 많아진다.

$$y = w_1x_1 + w_2x_2 + w_3x_3 + \dots + w_nx_n + b$$

나으로 혈압을 예측하는 문제


나이처럼 데이터 특성이 하나라면 선형 모델은 다음 1차 함수로 간단하게 표현

• 입력 자료로 파란색 데이터를 학습

- 모델은 학습으로 알지 못했던 매개변수인 a 와 b 를 각각 1.46, 58.7로 결정
 - 1차 함수에서 a 는 기울기(또는 가중치), b 는 y 축과 만나는 절편(또는 편향)

• 나이 70의 혈압을 예측

- 모델은 학습으로 파악한 1차 함수를 통해 $160.9(1.46 \times 70 + 58.7)$ 를 예측, 붉은 점이 (70, 160.9)



$$y = ax + b$$

y : 예측값

x : 특성

a : 기울기(가중치)

b : 절편(편향)



선형 모델은 회귀 뿐 아니라 분류에도 활용

- **선형 회귀**

- 데이터에 가장 적합한 선을 찾는 방법

- **선형 분류**

- 유형 클래스를 분류하는 가장 적합한 선을 찾는 방법



만일 입력 데이터의 특성의 수(차수)가 n 이라면 선형 모델의 식은 다음과 같다. 선형 모델이 학습을 통해 구해야 할 값이 $w_1, w_2, \dots, w_n, b$ 등 많아진다.

$$y = w_1x_1 + w_2x_2 + w_3x_3 + \dots + w_nx_n + b$$


지도 학습인 K-최근접 이웃 알고리즘(KNN: K-Nearest Neighbors)은 가장 간단한 알고리즘으로 회귀와 분류에 모두 사용

• KNN

- 새로운 자료에 대해
 - 기준으로 정한 가장 근접한 이웃 K개 중에서
 - 가장 많은 유형으로 분류하는 방법

• 사례

- 두 개의 특징 X, Y의 데이터에서
 - A와 B, 2개 클래스로 분류하는 문제
 - 별표는 클래스 A, 삼각형은 클래스 B
 - 새로운 데이터 ?
 - A와 B 중 무엇으로 분류해야 할까?



주위에 있는 데이터 분류 다수결에 의해 결정

- 특징 X, Y의 데이터에서

- A와 B, 2개 클래스로 분류하는 문제
- 새로운 데이터 ?

- A와 B 중 무엇으로 분류해야 할까?

- KNN 알고리즘

- K가 3

- ?와 가장 가까운 이웃 3개

- 녹색 점선 원으로 표시 중
- A는 1개, B는 2개

- 다수결에 의해 데이터 ?

- 클래스 B로 예측

- K가 7


- A는 4개, B는 3개이므로

- A로 예측

- 기준 K 값에 따라 예측이 달라질 수 있음

- 다양한 지도 학습의 다른 방법

- 서포트 벡터 머신
- 의사결정트리
- 랜덤 포레스트(random forest) 알고리즘



K-평균 군집화 알고리즘(K-means clustering algorithm)은 주어진 데이터를 비슷한 K개의 군집(클러스터)으로 묶는 알고리즘으로, 간단히 KC(K-means Clustering) 또는 K-평균 알고리즘

• 비지도 학습의 대표적 알고리즘

- 정답이 없는 입력 데이터에 정답을 붙이는 역할에 주로 사용
- 옆 그림, 군집화를 수행하는 과정의 이해

• K

- 알고리즘 적용 이전에 군집 수 K가 결정
 - 주어진 데이터로부터 그룹화할 그룹 수
 - 군집의 수
- 각 군집은 하나의 중심(centroid)을 가짐
- 동일한 자료에 대해 군집 수 K가 변하면 전혀 다른 결과

• 평균

- 각 군집의 중심과 데이터들의 평균 거리



06

인공지능과 딥러닝

단원 목차

6.1 인공지능 개요

6.2 머신러닝


6.3 인공신경망과 딥러닝



우리 인간의 뇌에는 1천억 개의 뉴런이라는 신경세포가 있음

• 뉴런

- 가지돌기(dendrite)(또는 수상돌기)에 들어온 여러 신호는 하나로 통합되어
 - 어떤 임계 값을 초과하면 축삭돌기(axon)를 통해 이동되고 다음 신경 세포에 전달



시냅스: 축삭돌기의 말단과 다음 뉴런의 가지돌기 사이 부분으로
전 뉴런에서 다음 뉴런으로 전달되는 부위를 말함


1957년 심리학자인 프랭크 로젠블랫(Frank Rosenblatt)는 세계 최초로 인공신경망인 퍼셉트론(perceptron)을 제시

• 퍼셉트론

- 다수 입력(input), 하나의 출력(output)
- 가중치(weights)
 - 입력의 강도(중용도)를 표현
- 스스로 학습하는 능력
 - 초기 가중치는 임의의 값 지정
 - 뉴런의 결과를 목표값과 비교
 - 그 차이인 오차(error)를 사용
 - 다시 그 다음 단계의 가중치에 반영

• 임계값 $-b$

- 가중치와 입력 곱의 합
 - 가중 합계(weighted sum)
 - $w_0 + x_1w_1 + x_2w_2 + \dots + x_nw_n$
 - 값이 임계값(threshold) $b(=-w_0)$ 보다 크면
 - 뉴런은 실행(fire), 결과값이 1
 - 그렇지 않으면
 - 0이 결과값



$$\sum_{i=1}^n w_i x_i \geq b \text{ 이면 } \hat{y} = 1$$

그렇지 않으면 $\hat{y} = 0$

퍼셉트론의 수식 $wx+b$ 에서 가중치 w 를 기울기 a 로 생각하면 결국 $ax+b$ 가 되어 기울기가 a , y 절편이 b 인 1차 함수와 같음

• 퍼셉트론 계산식

- 입력 특성은 x 하나이고 w 를 b 로 표현
 - 다음과 같은 간단한 수식의 퍼셉트론
- 입력 특성이 하나
 - 가중치는 기울기, 편향은 절편




그림 6.52 ▶ 입력 특성이 하나인 간단한 퍼셉트론

활성화 함수는 퍼셉트론의 최종 값의 세기를 조절하는 데 사용되며 활성화 함수 출력값은 다음 퍼셉트론의 입력으로 사용

- 퍼셉트론에서 최종 값을 결정하는 함수



- 퍼셉트론의 입력값과 가중치를 곱한 것에 편향을 모두 합한 값에 대한 함수

$$\sigma = \sum_i^n w_i x_i + b$$

- 함수 $f(\sigma)$

- 단위 계단 함수(unit step function)

- 로젠블랫의 활성화 함수
- 가중 합계(weighted sum)
 - 0 이상이면 결과는 1
 - 0 미만이면 0



$$f(\sigma) = \begin{cases} \sigma \geq 0 \text{이면 } 1 \\ \sigma < 0 \text{이면 } 0 \end{cases}$$

그림 6.54 ▶ 로젠블랫의 활성화 함수: 단위 계단 함수

활성화 함수는 다양한데 최근에 많이 사용하는 ReLU(Rectified Linear Unit) 함수



- **항등 함수(identity function)**

- 가장 단순한 활성화 함수는 입력 그대로 출력하는 $f(x)=x$

- **ReLU 함수**

- 양수 부분은 항등함수와 동일, 0 이하는 0

- **시그모이드(sigmoid) 함수와 하이퍼볼릭탄젠트(tanh) 함수**



가장 간단한 인공신경망(ANN: Artificial Neural Network)은 입력층(input layer)과 퍼셉트론의 출력층(output layer)으로 구성

• 아파트 가격 예측, 선형 회귀 문제

- 입력층, 4차원의 입력 특성
 - 크기, 방의 개수, 도심과의 거리, 건축 연수
 - 특징 수인 차수: 4
- 출력층, 하나의 퍼셉트론
 - 활성화 함수: 항등 함수
 - 입력의 가중치 곱의 합이 아파트 가격
- 편향은 그림에서 생략
- 학습
 - 훈련 데이터로 가중치와 편향을 결정
 - 4개의 가중치와 하나의 편향 값을 찾음
- 예측
 - 테스트 데이터로 출력인 아파트 가격을 예측




그림 6.56 ▶ 입력의 차원이 4인 단순 선형 회귀 문제의 인공신경망

여러 값이 입력되는 입력층(input layer)과 여러 개의 뉴런으로 구성되는 출력층(output layer)을 구성

• 다층 신경망(MLP: Multi-Layer Perceptron)

- 인공신경망을 확장해 가로로 여러 개 연결한 층(layer)을 쌓음
- 은닉층(hidden layer) 또는 중간층
 - 입력층과 출력층 사이를 여러 층으로 연결, 뉴런이 여러 개 연결되어 '깊은 사고'를 하는 것을 의미
 - 처리할 계산량이 기하급수적으로 늘어나 그만큼 정확도가 높아진 결과를 얻을 수 있음
- 깊은 딥러닝: 여러 층의 은닉층의 단계가 많아질수록




그림 6.57 ▶ 다층 퍼셉트론: MLP

인공신경망은 입력층과 은닉층 그리고 1개의 예측 값이 있는 출력층으로 구성된 사례

- 은닉층으로 5개의 퍼셉트론으로 구성

- 아파트 가격이 출력으로 나오는 출력층





그림 6.58 ▶ 입력의 차원이 4인 선형 회귀 문제에서 5개의 퍼셉트론을 은닉층으로 구성한 인공신경망

심층신경망(DNN: Deep Neural Network)은 입력층(input layer)과 출력층(output layer) 사이에 여러 개의 은닉층(hidden layer)들로 이뤄진 인공신경망으로 딥러닝이라고 불리움

- **심층신경망(DNN: Deep Neural Network)**

- 현재의 딥러닝은 적게는 몇 개에서 많게는 수백 개의 은닉층으로 구성
- 다양한 활용 분야
 - 항공기나 드론, 자동차의 자율비행, 필체인식 또는 음성인식 등 다양하게 이용



6개의 데이터로 학습시켜 2년 또는 12년 등의 원하는 연수의 월 급여를 예측

• SW경력(연수)에 따른 월 급여 예측 사례

- '소프트웨어 개발 분야 급여 수준' 데이터

• 산포도(scatter)

소프트웨어 개발 분야 급여 수준 자료

		신입사원	초급기능사	고급기능사	초급기술자	고급기술자	기술사
월급여(백만원)	y	2.6	3.1	4.3	6.5	8.4	11.2
sw경력(년수)	x	0	3	5	8	10	13

소프트웨어 개발 분야 급여 수준




그림 6.61 ▶ '소프트웨어 개발 분야 급여 수준' 자료와 산포도

매개변수 w 와 b 가 결정된 4개의 직선 중 어느 직선이 훈련 데이터를 표현하고 다른 데이터를 예측하는 가장 좋은 직선일까?

- 수식 $y=wx+b$ 에서 어떻게 w 와 b 를 찾을 수 있을까?

- 데이터 지점(파란색 원)을 가장 근접하는 직선

- 실제값 y 와 예측값 $\hat{y}$ (y hat) 차이인 오류를 최소화

- 손실 함수(loss function)

- 비용 함수(cost function)
- 학습의 목표가 되는 기준 지표의 계산식, 목적 함수(objective function)

- 오류를 최소화하는 방향으로 학습을 수행

- 손실과 비용이라는 용어

- 값이 작아질수록 목표에 접근

소프트웨어 개발 분야 급여 수준




그림 6.65 ▶ 데이터를 표현하고 예측하는 여러 직선

입력 데이터




그림 6.66 ▶ 손실함수 개념

인공신경망은 학습을 통해 지표인 손실 값을 줄이는 방향으로 가중치 w 와 편향 b 를 찾아야 함

- 경사하강법(傾斜下降法, gradient descent)

- 말 그대로 '경사 따라 내려가기' 방식
 - 기울기를 계산해 기울어진 방향으로 조금씩 이동하는 과정을 반복적으로 수행
 - 기울기가 최소가 되는 지점으로 이동하는 방식
- 손실함수의 값이 최소가 되는 지점을 찾아 가는 방법





그림 6.67 ▶ 경사하강법 개념

프레임워크는 툴킷(toolkit) 또는 라이브러리(library)라는 용어로도 사용

• 인공지능경망을 위한 공개된 프레임워크(software)는 매우 다양

- 오픈소스 소프트웨어는 소스가 공개되어 누구나 활용 가능
- 구글의 텐서플로(tensorflow)와 페이스북의 파이토치(Pytorch)

2018년 딥러닝 프레임워크 인기 순위



원래 구글 브레인(brain) 팀이 구글 내부에서 연구와 제품 개발을 위한 목적으로 만들어 사용하다가 공개한 오픈소스 소프트웨어

• 구글이 공개

- 머신러닝과 딥러닝을 위한 오픈소스 플랫폼
 - 2015년 11월
- 인공지능경망 중심의 머신러닝 구현 공개 라이브러리
- 다차원 데이터인 텐서(tensor)와 연산의 흐름
 - 데이터 흐름 그래프(data flow graph)를 사용한 수치 연산
- 데스크탑, 서버 혹은 모바일 기기에서 실행
- CPU(Central Processing Unit)나 GPU(Graphical Processing Unit)를 사용




그림 6.71 ▶ 텐서플로 홈페이지(www.tensorflow.org)

컴퓨터 비전 및 자연어처리와 같은 응용 분야에 사용되는 토치(torch) 라이브러리를 기반으로 하는 파이썬을 위한 오픈소스 머신 러닝 라이브러리

- **페이스북 인공지능 연구팀(FAIR: Facebook AI Research)에서 개발**

- 2016년에 오픈소스로 공개
 - 2018년 12월 1.0 버전을 정식 출시
- 풍부한 성능 개선
- 모바일 플랫폼용 개발자 친화적인 지원
 - 최근 사용 비중이 높아지고 있음

- **파이토치로 만들어진 대표적인 인공지능 소프트웨어**

- 테슬라의 오토파일럿(Autopilot)
- 우버의 파이로(Pyro)

- **OpenAI(openai.org)의 주개발 플랫폼**

- 2015년 10월, 일론 머스크 등이 인류에게 이익을 주며 인간 친화적인 인공지능 연구를 목표로 설립




그림 6.74 ▶ 파이토치 홈페이지(pytorch.org)